Instrucciones

(el lenguaje assembly RISC-V)

Arquitectura de Computadores

Todo computador debe tener instrucciones para ejecutar las operaciones aritméticas básicas; p.ej.:

```
add a,b,c -suma\ las\ variables\ \mathbf{b}\ y\ \mathbf{c}\ y\ pone\ la\ suma\ en\ \mathbf{a}
```

La notación (a este nivel) es rígida:

 cada instrucción aritmética ejecuta sólo una operación y siempre debe tener exactamente tres variables

P.ej., para sumar cuatro variables $-\mathbf{b}$, \mathbf{c} , \mathbf{d} y \mathbf{e} — y poner la suma en \mathbf{a} se necesitan tres instrucciones, cada una en una línea por sí sola:

```
add a,b,c
add a,a,d
add a,a,e
```

P.ej., ¿cómo traduciría el compilador el siguiente segmento de un programa en C o Python a instrucciones del lenguaje assembly?

$$a \leftarrow b + c$$

 $d \leftarrow a - e$

Respuesta:

P.ej., ¿qué haría el compilador en el caso de la siguiente sentencia?

$$f \leftarrow (g+h) - (i+j)$$

Respuesta:

t0 y **t1** son variables auxiliares para almacenar temporalmente los resultados de **g+h** e **i+j** antes de hacer la resta

A diferencia de un programa en C o Java, los tres operandos de las instrucciones aritméticas deben corresponder a **registros**:

- hay un número limitado de registros, p.ej., 32
- en RISC-V, son de 64 bits de largo c/u

Para los nombres de los registros, RISC-V usa una **x** seguida del número del registro (un número entre 0 y 31)

P.ej., si las variables **f**, **g**, **h**, **i** y **j** están asignadas a los registros **x19**, **x20**, **x21**, **x22** y **x23**

... y usamos los registros **x5** y **x6** para almacenar los resultados intermedios


... entonces el código compilado para $f \leftarrow (g + h) - (i + j)$ sería

add x5,x20,x21 add x6,x22,x23 sub x19,x5,x6 Los lenguajes de programación también tienen arreglos (y otras estructuras), que pueden contener muchos más datos que la cantidad de registros del computador

Estas estructuras, que simplemente no caben en 32 registros, se almacenan en la memoria del computador:

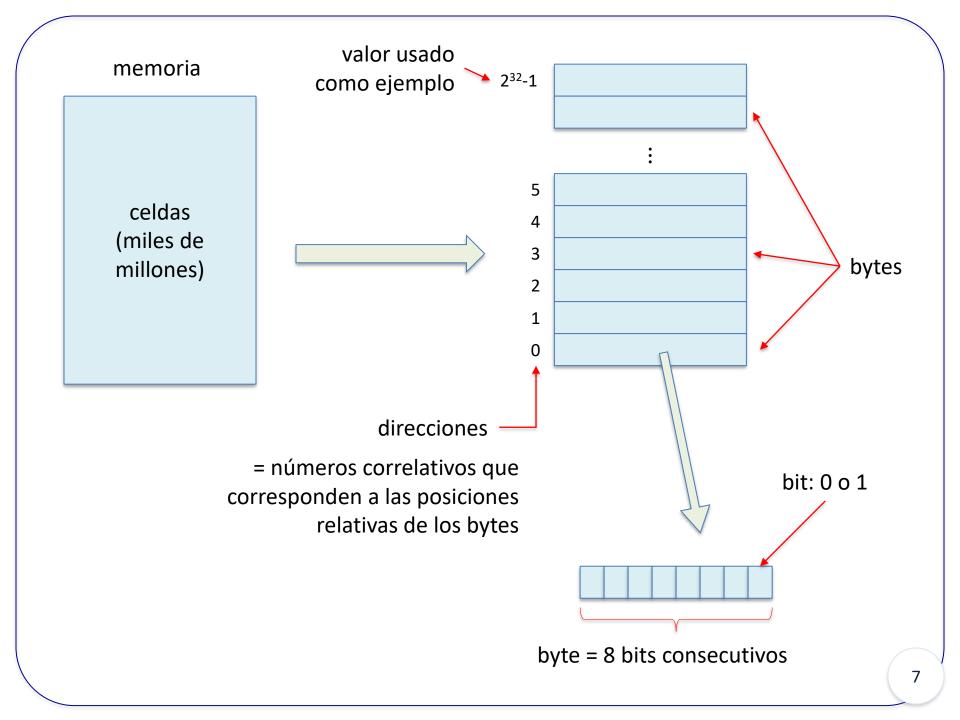
que tiene capacidad para almacenar miles de millones de datos

... \rightarrow el lenguaje assembly debe tener instrucciones para *transferir* datos entre la memoria y los registros: **1d** y **sd**



La memoria es como un arreglo unidimensional muy grande de celdas o casillas, en que la *dirección* (de memoria) actúa como índice:

- 1d y sd deben especificar la dirección de la celda involucrada
- 1d y sd especifican la dirección de modo indirecto, por una constante y un registro → la suma de la constante y el contenido del registro



1d: copia datos desde la memoria a un registro (load doubleword)

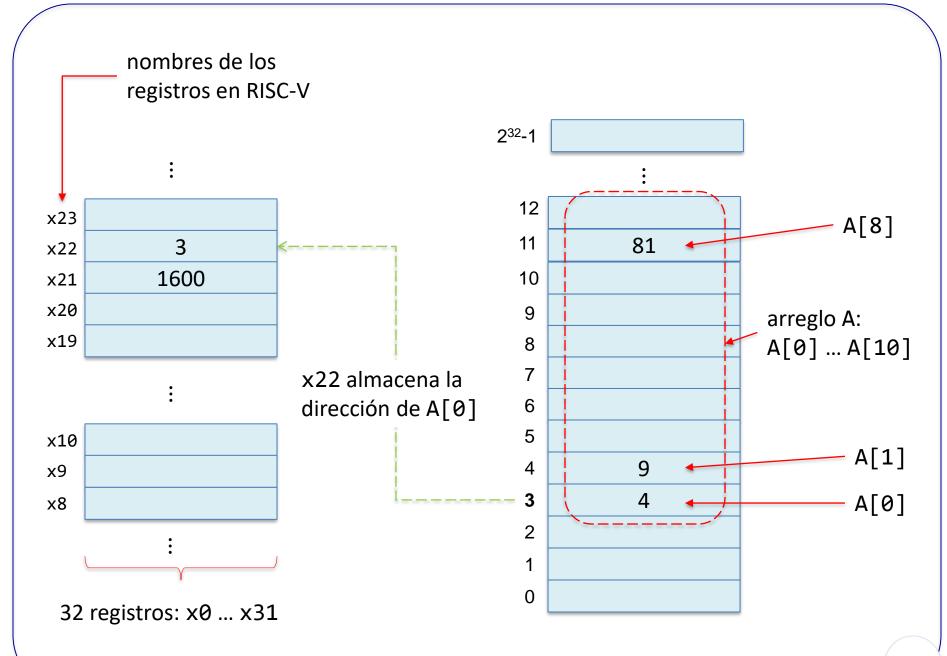
P.ej., ¿cómo traduce el compilador la sentencia $g \leftarrow h + A[8]$ en C?

- el compilador coloca el arreglo A en memoria → sabe cuál es la dirección de memoria de A[0] (el primer elemento de A) y coloca esta dirección en un registro, llamado el registro base; supongamos que el registro base es x22
- el compilador asocia variables con registros → supongamos que las variables
 g y h están asociadas a los registros x20 y x21

Entonces $g \leftarrow h + A[8]$ es traducida por el compilador así:

ld x9,8(x22) add x20,x21,x9 -dos instrucciones en assembly:

- -... primero, copia A[8] al registro x9
- -... luego, suma y pone el resultado en g



La memoria, en la práctica en todos los computadores, está organizada en *bytes* (8 bits consecutivos)

... en que cada byte tiene una dirección: 0, 1, 2,

Los computadores modernos, sin embargo, operan sobre *palabras* (*words*) de 4 bytes consecutivos (32 bits),

... o, como en el caso de RISC-V, incluso sobre *palabras dobles* (*doublewords*) de 8 bytes consecutivos (64 bits)

... por lo que las direcciones de estas palabras dobles son 0, 8, 16, ...

- ... es decir, la dirección correspondiente al primer byte de la palabra
- ... de modo que el ejemplo anterior requiere un ajuste

Veámoslo con la siguiente instrucción

palabra doble = 8 bytes consecutivos (64 bits) memoria RISC-V $2^{32}-8$ 40 32 palabras dobles (c/u de 8 bytes) 24 16 8 0 direcciones (de las palabras dobles): corresponden a la dirección de uno de los 8 bytes de la palabra —el byte con la dirección numéricamente menor 11

sd: copia datos desde un registro a la memoria (*store doubleword*):

$$A[12] \leftarrow h + A[8]$$
 -sentencia en C, Java, etc.

De nuevo, x22 contiene la dirección de A[0] y x21 está asociado a h:

-tres instrucciones en assembly:

- -... copia (load) A[8] al registro x9
- -...suma ha A[8]
- -... copia (store) el registro x9 a A[12]

En muchas operaciones, aparecen operandos constantes, o *inmediatos*: el valor numérico propiamente tal

RISC-V tiene versiones de las instrucciones aritméticas en que uno de los operandos es una constante

P.ej., la instrucción add-immediate, or addi:

addi x22,x22,4 — $corresponde\ a\ la\ sentencia\ x22 \leftarrow x22 + 4$

Es útil poder operar sobre conjuntos de bits dentro de una palabra o incluso sobre bits individuales —operaciones lógicas, típicamente:

AND, OR, XOR, NOT, shift left, shift right y shift right arithmetic

Los *shifts* mueven todos los bits de una palabra a la izquierda o a la derecha, llenando los bits que quedan "vacíos" con 0s:

P.ej., si **x19** contiene

$$(=9_{10})$$

... y ejecutamos la instrucción

... \rightarrow shift left de 4 posiciones y dejamos el resultado en **x11**:

$$0000\ 0000\ 0000\ 0000\ 0000\ 1001\ 0000_{2}$$
 (= 144₁₀)

El lenguaje assembly también tiene la instrucción shift right logical immediate (srli)

... y las versiones de estas instrucciones en que la cantidad de bits desplazados es especificada en un registro y no como una constante:

shift left logical (s11) y shift right logical (sr1)

En el caso de *shift right*, el lenguaje tiene además las instrucciones en que los bits que quedan "vacíos" a la izquierda se llenan con copias del bit de signo original (y no necesariamente con 0s):

shift right arithmetic immediate (srai) y shift right arithmetic (sra)

and y or : operaciones bit a bit entre los contenidos de dos registros

P.ej., si

 $\mathbf{x10} = 0000\ 0000\ 0000\ 0001\ 1100\ 0000\ 0000_2$

 $\mathbf{x11} = 0000\ 0000\ 0000\ 0000\ 1101\ 1100\ 0000_2$

... entonces la ejecución de

and x9,x10,x11 — $la\ sentencia\ en\ C\ podría\ ser\ r \leftarrow s\ \&\ t$

... deja

 $x9 = 0000 0000 0000 0000 1100 0000 0000_{2}$

Todo lenguaje de programación

... incluyendo los lenguajes de máquina y los lenguajes assembly

... deben tener instrucciones para controlar la ejecución condicional de otras instrucciones:

- dependiendo de los datos de entrada y de los valores creados durante la ejecución del programa,
 - ... se ejecutan unas instrucciones u otras

En el assembly RISC-V:

beq registro1, registro2, L1

... significa "ir a la instrucción etiquetada *L1* si el valor en *registro1* **es igual** al valor en *registro2*" —*branch if equal*

bne registro1, registro2, L1

... significa "ir a la instrucción etiquetada *L1* si el valor en *registro1* **no es igual** al valor en *registro2*" — *branch if not equal*

P.ej., compilemos la siguiente sentencia a RISC-V:

```
if (i = j):

f \leftarrow g + h

else:

f \leftarrow g - h
```

Si las variables **f**, **g**, **h**, **i** y **j** corresponden a los registros **x19** a **x23**:

bne x22,x23,**Else** add x19,x20,x21 beq x0,x0,**Exit**

Else: sub x19, x20, x21

Exit:

beq x0,x0,Exit es en la práctica un branch incondicional (ya que x0 es siempre igual a x0) a la instrucción etiquetada Exit

El *assembler* (ensamblador) libera al compilador y al programador de tener que calcular las direcciones (de memoria) para los *branches*

Las decisiones también son importantes para repetir la ejecución de una computación -loops

Las mismas instrucciones condicionales sirven para estos casos

P.ej., compilemos el siguiente loop:

```
while (save[i] = k):

i \leftarrow i+1
```

Supongamos que i y k corresponden a los registros x22 y x24, save[0] está en x25, y queremos guardar save[i] en x9

Primero, necesitamos la dirección de **save[i]**: sumamos **i** a la base de **save**, por lo que antes hay que multiplicar **i** por **8**, lo que en este caso hacemos empleando *shift left logical immediate*:

```
Loop:
      slli
              x10, x22, 3
                                 —multiplicación i*8
                                 -suma i + save[0]
       add
              x10, x10, x25
       ld
               x9,0(x10)
                                 -carga save[i] en x9
       bne
              x9,x24,Exit
                                 —el test del loop
       addi
                                 —incremento de i
              x22, x22, 1
              x0, x0, Loop
                                 —volvemos al principio
       beq
Exit:
```

Además de chequear igualdad (**beq**) o desigualdad (**bne**), a veces es útil chequear si una variable es menor que otra

La instrucción

blt registro1, registro2, L1

... salta a la instrucción etiquetada *L1* si *registro1* < *registro2*, cuando los valores son tratados como números con signo:

• **bltu** salta si *registro1* < *registro2*, cuando los valores son tratados como números sin signo (*branch if less than, unsigned*)

También tenemos las instrucciones bge y bgeu:

- saltan si el valor en el primer registro es al menos tan grande como el valor en el segundo registro (branch if greater than or equal)
 - ... para números con signo y sin signo, respectivamente

Una **función** (procedimiento o subrutina) es una herramienta que los programadores usamos para estructurar un programa:

- los programas son más fáciles de entender
- el código puede ser reusado

Los *parámetros* de la función actúan como una interfaz entre la función y el resto del programa y datos:

- pasan valores
- devuelven resultados

Al ejecutar la función, el programa debe seguir estos seis pasos:


- poner los parámetros en un lugar donde la función tenga acceso a ellos
- transferir el control a la función
- obtener la memoria necesaria para la ejecución de la función
- ejecutar la tarea correspondiente
- poner el resultado en un lugar donde el programa que hizo la llamada tenga acceso a él
- devolver el control al punto de origen, ya que una función puede ser llamada desde varios puntos en un programa


Los registros son el lugar de más rápido acceso para tener datos en un computador

En RISC-V hay 32 registros

... al llamar a una función, los usamos así:

- x10 x17: ocho registros para pasar parámetros o retornar valores
- x1: un registro para la dirección de retorno para volver al punto de origen de la llamada





RISC-V tiene además la instrucción jump&link sólo para funciones:

- jal x1, direccióndelaFunción
 - ... salta a la dirección direccióndela Función

... y simultáneamente guarda la dirección de la siguiente instrucción —la dirección de retorno— en el registro **x1**

(la dirección de retorno es necesaria porque la misma función podría ser llamada desde varias partes del programa)

... y la instrucción jump&link register para volver desde una función:

- jalr x0,0(x1)
 - ... salta a la dirección almacenada en x1 (x0 está hard-wired con el valor 0)

El programa que hace la llamada primero pone los valores de los parámetros en los registros x10 - x17

... y luego ejecuta jal x1, F para saltar (al código correspondiente) a la función F y guardar la dirección de retorno en x1:

 por supuesto, el registro PC — program counter — tiene la dirección de la instrucción que está siendo ejecutada en este momento

... por lo que **jal** pone realmente **PC** + 4 en **x1**

La función **F** entonces hace sus cálculos (o lo que sea)

... pone los resultados en los mismos registros **x10** – **x17**

... y finalmente devuelve el control al programa que hizo la llamada ejecutando jalr x0,0(x1)

Si al llamar a una función el compilador necesita más registros que los ocho registros x10 - x17, entonces

... todos los registros adicionales que sean usados deben ser finalmente restaurados a los valores que tenían antes de que se produjera la llamada —recuperar sus valores originales:

 Jos valores originales de esos registros deben ser guardados en la memoria mientras dura la llamada a la función

La estructura de datos para esto es un **stack** —una cola del tipo "el último en entrar es el primero en salir", o LIFO

... y un puntero —el *stack pointer* o **sp**, almacenado en el registro **x2**— a la dirección más recientemente reservada en el stack para estos registros adicionales

P.ej., ¿cuál es el código assembly compilado de la siguiente función?

```
int xmpl(int g, int h, int i, int j):

int f

f \leftarrow (g+h) - (i+j) - ver diap. 4

return f
```

Los parámetros **g**, **h**, **i** y **j** corresponden a los registros **x10**, **x11**, **x12** y **x13**

La variable **f** corresponde al registro **x20** (este es un registro adicional)

Además, para calcular el valor de **f**, usamos dos registros temporales: **x5** y **x6** (también adicionales)

Así, primero guardamos en el stack los valores de los registros **x5**, **x6** y **x20** —tres palabras dobles (24 bytes)— para poder usarlos durante la ejecución de la función:

```
addi sp, sp, -24 — ajustamos el stack

sd x5, 16(sp) — guardamos el contenido de x5


sd x6, 8(sp) — guardamos el contenido de x6

sd x20, 0(sp) — guardamos el contenido de x20
```

Luego, calculamos el valor de la expresión y los guardamos en x20:

```
add x5, x10, x11
add x6, x12, x13
sub x20, x5, x6
```

... y para retornarlo lo guardamos en **x10** —un registro de parámetro:



Antes de volver al punto donde se produjo la llamada, restauramos los valores de los tres registros guardados en el stack:

```
ld x20, 0(sp)
ld x6, 8(sp)
ld x5, 16(sp)
addi sp, sp, 24
```

... y finalmente retornamos, ejecutando

jalr
$$x0$$
, $\theta(x1)$

En realidad, no siempre es necesario guardar en el stack los valores de los registros adicionales

... p.ej., cuando no representan valores de variables del programa, sino resultados intermedios:

- en RISC-V, los registros x5 a x7 y x28 a x31 son registros temporales que no son preservados durante una llamada a una función
- ... mientras que los registros **x8**, **x9**, y **x18** a **x27** son registros que, si son usados, deben ser preservados durante una llamada a una función

Esto significa que en el ej. anterior podemos ahorrarnos los dos *loads* y los dos *stores* de **x5** y **x6**

¿Qué pasa en el siguiente caso?

```
int factorial(int n):
    if n < 1:
        return 1
    else:
        return n*factorial(n-1)</pre>
```

Como la función es recursiva, ahora también es necesario guardar en el stack los valores de los registros **x10** (el parámetro) y **x1** (la dirección de retorno), para poder recuperarlos al volver a la llamada anterior:

```
factorial:
    addi    sp, sp, -16
    sw     x1, 8(sp)
    sw     x10, 0(sp)
```

Luego, comparamos **n** con 1 (en realidad, **n**-1 con 0), y vamos al *label* **L1** si **n** \geq 1:

```
addi x5, x10, -1 bge x5, x0, L1
```

Si **n** < 1, entonces **factorial** devuelve 1, a través del registro **x10**:

```
addi x10, x0, 1
addi sp, sp, 16
jalr x0, 0(x1)
```

Si **n** ≥ 1, **n** es decrementado y **factorial** es llamado recursivamente:

L1: addi x10, x10, -1 jal x1, factorial

De ahí, empezamos a "salir" de (esta llamada de) la función:


```
addi x6, x10, 0
ld x10, 0(sp)
ld x1, 8(sp)
addi sp, sp, 16
```

... ponemos en **x10** el producto de **x10** y **x6**:

... y finalmente, **factorial** salta de nuevo a la dirección de retorno:

jalr
$$x0$$
, $\theta(x1)$

El stack, en la memoria



antes de la llamada durante la Ilamada después de la llamada